

# REDUCCIÓN Y VISUALIZACIÓN DE DATOS (2023) - PRÁCTICA 2

## Componentes principales

**2.1** Dado un vector aleatorio  $\mathbf{x} \in \mathbb{R}^3$  de media cero, y matriz de varianzas y covarianzas

$$\Sigma = \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 5 \end{pmatrix}$$

- Calcular los autovalores y autovectores de  $\Sigma$  y reescribirla como  $\Sigma = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^t$ , donde  $\mathbf{U}$  es ortonormal y  $\mathbf{\Lambda}$  es diagonal.
- Definir las componentes principales  $\xi_j$ , con  $j \in \{1, 2, 3\}$ , en función de las variables originales  $X_j$ . Escribir la transformación lineal del vector  $\mathbf{x}$  al vector  $\boldsymbol{\xi} = (\xi_1 \ \xi_2 \ \xi_3)^t$  usando un producto matricial de la forma  $\boldsymbol{\xi} = \mathbf{A}^t \mathbf{x}$ , donde las columnas de  $\mathbf{A}$  son las direcciones de proyección.
- Calcular la matriz de varianzas y covarianzas de  $\boldsymbol{\xi}$ . ¿Qué observa?
- Llamamos *variabilidad total* de un vector aleatorio a la traza de su matriz de varianzas y covarianzas. Calcular la variabilidad total de  $\mathbf{x}$  y la de  $\boldsymbol{\xi}$ . ¿Qué observa?
- ¿Qué porcentaje de la variabilidad total se conserva si definimos a  $\boldsymbol{\xi}$  únicamente con las primeras dos dimensiones?
- Una observación de  $\mathbf{x}$  resulta  $(2 \ 2 \ 1)^t$ , ¿Qué valores toman las componentes principales?
- Estimar la matriz  $\text{Cov}(\mathbf{x}, \boldsymbol{\xi})$ .

**2.2** Dado un vector aleatorio  $\mathbf{x} \in \mathbb{R}^p$ , con media  $\boldsymbol{\mu}$  y matriz de varianzas y covarianzas  $\Sigma$ , llamamos *estandarización multivariante* al resultado de hacer

$$\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu}),$$

lo que produce un vector en  $\mathbb{R}^p$ , llamémoslo  $\mathbf{z}$ .

- Calcular  $E(\mathbf{z})$  y  $\text{Cov}(\mathbf{z})$ . ¿Qué observa?
- ¿Qué relación tiene la estandarización multivariante a la estandarización por columnas hecha en el ejercicio 1.1?
- ¿Qué relación tiene la estandarización multivariante con la transformación necesaria para obtener las componentes principales de  $\mathbf{x}$ ?
- Simular una nube de puntos de tamaño  $n = 1000$  con distribución Normal en  $\mathbb{R}^3$  y los parámetros  $\boldsymbol{\mu}$  y  $\Sigma$  del ejercicio 2.1. Aplicar la estandarización multivariante a estos datos y visualizar la nube antes y después de la transformación mediante *scatterplots* de pares. ¿Qué observa? (Nota: Usar los valores poblacionales conocidos de  $\boldsymbol{\mu}$  y  $\Sigma$ ).

**2.3** Se recolecta información sobre proyectos inmobiliarios en un vector aleatorio  $\mathbf{x}$  de media  $\boldsymbol{\mu} \in \mathbb{R}^3$  y varianza  $\boldsymbol{\Sigma} \in \mathbb{R}^{3 \times 3}$ . Las componentes son  $X_1$  = duración media de la hipoteca (años),  $X_2$  = precio (millones de euros) y  $X_3$  = superficie de la cocina ( $\text{m}^2$ ). Se dispone de observaciones de una muestra de  $n = 10$  proyectos en el archivo `constructora.txt`.

- a. Centrar los datos y realizar *scatterplots* de pares.
- b. Obtener las componentes principales muestrales a partir de una estimación de  $\text{Cov}(\mathbf{x})$ . Escribir la transformación lineal necesaria a los datos para obtener los *scores* en dimensión 2.
- c. Graficar los *scores* e interpretar la posición de los puntos. ¿Qué variable o variables tienen más peso en cada componente?
- d. Estimar la matriz de covarianzas del vector completo de componentes principales y compararla con la estimación disponible de  $\boldsymbol{\Sigma}$ . ¿Qué observa? ¿Qué proporción de la variabilidad total capturan las primeras dos componentes?
- e. Repetir el análisis obteniendo los *scores* a partir de una estimación de  $\text{Corr}(\mathbf{x})$  y comentar las diferencias.

**2.4** El archivo `países_mundo.csv` tiene indicadores económicos y sociales de 96 países en algún momento de la década de los 90. Las variables son la tasa de mortalidad infantil cada 1000 nacidos vivos (`mortinf`), producto nacional bruto (PNB), producción de electricidad (`prod.elec`), consumo de energía per cápita (`cons.energia`) y emisión de CO2 per cápita (`CO2`). Se tiene la siguiente hoja de ruta para realizar un análisis de los datos:

- 1 Realizar un *scatterplot* de pares. Comentar sobre la linealidad y de los datos y su ajuste con una distribución Normal.
  - 2 Obtener y graficar los *scores* de PCA en sus dos primeras coordenadas. ¿Cómo se puede interpretar la ubicación de los países?
  - 3 Calcular la proporción de variabilidad total acumulada por las dos primeras coordenadas de los *scores*.
  - 4 Realizar un *heatmap* de la correlación muestral entre los *scores* y los datos. ¿Qué variables son las que inciden más en cada componente principal? ¿Tiene sentido calcular coeficientes de correlación?
- a. Se propone recorrer esta ruta partiendo de tres escenarios distintos:
    - i. Los datos originales, sin estandarizarlos por columnas.
    - ii. Tomar logaritmo natural de los datos y usarlos sin estandarizar por columnas.
    - iii. Tomar logaritmo natural a los datos y luego estandarizarlos por columnas.
  - b. ¿Cómo se podría detectar si hay observaciones atípicas? ¿Afectan sensiblemente al análisis de componentes principales?

**2.5** (Construcción de un *biplot* de componentes principales) El archivo `vinos.csv` contiene información sobre 4 variables medidas a 1580 botellas de vino tinto. Reproducir la siguiente representación en dos dimensiones:



*Ayuda:* Las coordenadas de los puntos corresponden a los *scores* de PCA de los datos estandarizados por columnas, mientras que las direcciones de las flechas corresponden a las coordenadas de las variables. En la librería base de R usar las funciones `arrows` y `text`.

## Coordenadas discriminantes

*En construccion.*

## Correlación canónica

*En construccion.*

## Projection pursuit

*En construccion.*

## Bonus

*En construccion.*